

Generator pametnih šifri

Viktor Braut, Matija Osrečki i Dino Sulić

7. siječnja 2014.

Sažetak

Za većinu korisnika sigurnost na računalnim sustavima bazira se na kvalitetnoj šifri. Ovaj rad predstavlja pristup generiranju kvalitetnih šifri na temelju lakoće utipkavanja istih. Za analizu lakoće utipkavanja naučili smo neuronsku mrežu da regresijom ocjeni lakoću utipkavanja nizova znakova fiksne duljine (engl., *n-gram*), u našem slučaju veličine 3. Optimalne parametre neuronske mreže odredili smo unakrsnom validacijom nad skupom od oko 440 podnizova koristeći 4 preklopa. Iako rezultati jako variraju, u konačnici smo dobili dovoljno dobre rezultate za izradu generatora. Generator koristi jednostavnu tehniku gdje kreće s slučajnom odabranom kratkom šifrom dobre kvalitete i svaki sljedeći znak bira stohastički na temelju kvalitete novodobivenog zadnjeg podniza.

1. Uvod

Sigurnost privatnosti na računalnim sustavima danas je bitna više nego ikada. Za većinu korisnika to znači jednu stvar – kvalitetna šifra. I dok sustavi poput Gmail-a ugrađuju metode dodatne verifikacije korisnika putem tokena generiranih primjerice mobilnim uređajem te postoje rješenja sigurnosti uporabom kriptografskih metoda javnih i privatnih ključeva (SSH, GPG, itd.), za većinu web servisa, operacijskih sustava i ostalih oblika programske potpore kvalitetna šifra je najzastupljenije rješenje.

Više je svojstava kvalitetne šifre. Najbitnije svojstvo je sigurnost – mora biti dovoljne duljine, sadržavati dovoljno različitih vrsta znakova (mala i velika slova, brojevi i ostali znakovi) koji bi trebali biti slučajno raspoređeni, kako pojedini dijelovi šifre ne bi bile konkretne riječi. Drugo poželjno svojstvo je da je šifru lagano zapamtiti. Nažalost, za većinu

je to najbitnije svojstvo zbog čega za šifre koriste imena svojih djevojki, velikih kantautora (Bob) i slično.

U ovom radu predstavljamo ideju izbora, odnosno generiranja šifre na temelju lakoće utipkavanja iste. Prva pretpostavka je da će takav način zastupati sve znakove na tipkovnici u podjednakoj mjeri te da zbog slučajne prirode generiranja šifri neće doći do podnizova koji se mogu naći u rječnicima, prema tome bi trebalo biti zadovoljeno svojstvo sigurnosti. Druga pretpostavka je da lakoća utipkavanja olakšava mehaničko pamćenje i da će time biti zadovoljeno drugo svojstvo dobre šifre, iako možda tek nakon kraćeg perioda uvježbavanja šifre.

Uži aspekt ovog zadatka koji je i ujedno najteži jest analiza lakoće utipkavanja proizvoljnih nizova znakova na tipkovnici određenog rasporeda znakova. Pristup koji smo prirodno prihvatili jest uporaba subjektivnih ocjena skupa kraćih nizova u nadi da postoje nekakva statistička ili geometrijska korelacija između transformiranih nizova znakova i naših subjektivnih ocjena. Konkretno, koristili smo neuronske mreže kako bi regresijom odredili lakoće utipkavanja nizova znakova koje nismo vidjeli.

2. Metode

Pošto različiti rasporedi tipki utječu na lakoću utipkavanja, korišten je US raspored tipki. Također ne koristimo znakove za koje je potrebna tipka **shift** i podrazumijeva se da nitko ne koristi **capslock**. Prema tome, sva slova su mala i koristi se podskup znakova. Znakovi `\` i `|` su na US tipkovnici na tipki koja je ponekad iznad, a ponekad lijevo od tipke **enter**, zbog čega također nisu korištene.

2.1. Analiza lakoće tipkanja

2.1.1. Tehnika n-grama

Pretpostavka koju koristimo prilikom analize lakoće utipkavanja proizvoljnog teksta jest da ako uzmemo sve moguće podnizove fiksne duljine (n -grame), lakoća utipkavanja tog niza znakova odgovara prosjeku ocjena lakoća utipkavanja svih njegovih n -grama. Ta se pretpostavka temelji na više intuitivnih ideja. Prva je da ako su n -grami dovoljno dugi i dovoljno kvalitetni, ono što je trebalo utipkati prije n znakova nije toliko bitno, tj. toliko daleka povijest nema utjecaj na ono što slijedi. Druga ideja je da prilikom učenja utipkavanja neke šifre, korisnik će prirodno grupirati slova u manje grupe veličine 3 do 5, koje će moći instantno utipkati ako su kvalitetne. Time ujedno olakšavamo označavanje primjera, smanjujemo broj ulaznih kombinacija i omogućujemo učenje neuronskim mrežom.

2.1.2. Generiranje značajki

Za svaki znak generiramo 8 značajki, koji se mogu podijeliti u tri grupe:

- Koordinate trenutne tipke (2)
- Polarne koordinate vektora od prethodne do trenutne tipke (2)
- Polarne koordinate vektora od lijeve i desne tipke `alt` do trenutne tipke (4)

Pritom se vrijednosti svih značajki normaliziraju na interval $[-1, 1]$.

Koordinate su temelj svih ovih značajki. Koordinatni sustav je postavljen sa $(0, 0)$ na tipki 1. Svaka tipka je kvadrat veličine 1 sa 1 i udaljenost između tipki je 0.2.

2.2. Stohastički generator šifri

3. Rezultati

4. Zaključak

Literatura

Ovo smo radili isključivo prema vlastitom nađenoju. Na internetu je teško naći materijale na ovu

temu. Kao pomoć, koristili smo isključivo dokumentacije programskih biblioteka koje smo koristili (`neurolab`, `numpy`).

Dodatak A: programsko ostvarenje